Task03：详读西瓜书+南瓜书第4章

2021年10月24日 20:08

第四章 决策树

4.1 基本流程

简单直观的“分而治之”策略，是一个递归划分的过程

三种情况导致递归返回：

1. 当前节点包含的样本全部属于统一类别，无需划分
2. 当前属性集为空，或是所有样本在所有属性上取值相同，无法划分？
3. 当前节点包含的样本集为空，不能划分

4.2划分选择

决策树学习的关键是第8行，即如何选择最优划分属性，一般而言，随着划分的进行，希望分枝节点所包含的样本尽可能属于统一类别

4.2.1信息增益

信息熵：度量样本集合纯度的一种常用指标

$$\mathrm{Ent}(D) = -\sum_{k=1}^{|\mathcal{Y}|} p_k \log_2 p_k \ .$$

其中，p_k 表示当前样本集合D中第k类样本所占集合的比例

Ent(D)的值越小，则D的纯度越高

信息增益

（选用哪种属性对当前进行划分呢？根据按不同属性划分后的信息熵越小越好，因此计算信息增益）

假定离散属性a有V个可能的取值{a1,a2,a3,a4…aV}，给分枝节点赋予权重$|D^V|/|D|$,即样本数越多的分枝节点的影响越大，那么可按属性a计算出若按a划分的后的信息熵变化，通过计算“信息增益”

$$\mathrm{Gain}(D,a) = \mathrm{Ent}(D) - \sum_{v=1}^{V} \frac{|D^v|}{|D|} \mathrm{Ent}(D^v) \ .$$

一般而言，信息增益越大，则按属性a进行划分所获得的“纯度提升越大”

示例：

表 4.1 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

根节点信息熵为

$$\mathrm{Ent}(D) = -\sum_{k=1}^{2} p_k \log_2 p_k = -\left(\frac{8}{17}\log_2\frac{8}{17} + \frac{9}{17}\log_2\frac{9}{17}\right) = 0.998\ .$$

然后, 我们要计算出当前属性集合 {色泽, 根蒂, 敲声, 纹理, 脐部, 触感} 中每个属性的信息增益. 以属性“色泽”为例, 它有 3 个可能的取值: {青绿, 乌黑, 浅白}. 若使用该属性对 D 进行划分, 则可得到 3 个子集, 分别记为: D^1 (色泽=青绿), D^2 (色泽= 乌黑), D^3 (色泽=浅白).

子集 D^1 包含编号为 {1, 4, 6, 10, 13, 17} 的 6 个样例, 其中正例占 $p_1 = \frac{3}{6}$, 反例占 $p_2 = \frac{3}{6}$; D^2 包含编号为 {2, 3, 7, 8, 9, 15} 的 6 个样例, 其中正、反例分别占 $p_1 = \frac{4}{6}$, $p_2 = \frac{2}{6}$; D^3 包含编号为 {5, 11, 12, 14, 16} 的 5 个样例, 其中正、反例分别占 $p_1 = \frac{1}{5}$, $p_2 = \frac{4}{5}$. 根据式(4.1)可计算出用“色泽”划分之后所获得的 3 个分支结点的信息熵为

$$\mathrm{Ent}(D^1) = -\left(\frac{3}{6}\log_2\frac{3}{6} + \frac{3}{6}\log_2\frac{3}{6}\right) = 1.000\ ,$$

$$\mathrm{Ent}(D^2) = -\left(\frac{4}{6}\log_2\frac{4}{6} + \frac{2}{6}\log_2\frac{2}{6}\right) = 0.918\ ,$$

$$\mathrm{Ent}(D^3) = -\left(\frac{1}{5}\log_2\frac{1}{5} + \frac{4}{5}\log_2\frac{4}{5}\right) = 0.722\ ,$$

色泽的信息增益为

$$
\begin{aligned}
\mathrm{Gain}(D, \text{色泽}) &= \mathrm{Ent}(D) - \sum_{v=1}^{3} \frac{|D^v|}{|D|} \mathrm{Ent}(D^v) \\
&= 0.998 - \left(\frac{6}{17} \times 1.000 + \frac{6}{17} \times 0.918 + \frac{5}{17} \times 0.722 \right) \\
&= 0.109 \ .
\end{aligned}
$$

类似的, 我们可计算出其他属性的信息增益:

$\mathrm{Gain}(D, \text{根蒂}) = 0.143$; $\mathrm{Gain}(D, \text{敲声}) = 0.141$;

$\mathrm{Gain}(D, \text{纹理}) = 0.381$; $\mathrm{Gain}(D, \text{脐部}) = 0.289$;

$\mathrm{Gain}(D, \text{触感}) = 0.006$.

属性“纹理”的信息增益最大，于是选择纹理作为划分属性。

图 4.3 基于“纹理”属性对根结点划分

对子节点进行递归划分

4.2.2增益率

信息增益准则对可取数目较多的属性有所偏好，著名的CP4.5决策树算法通过使用增益率（gain ratio）来选择最优划分属性

$$
\mathrm{Gain_ratio}(D, a) = \frac{\mathrm{Gain}(D, a)}{\mathrm{IV}(a)} \ ,
$$

其中

$$
\mathrm{IV}(a) = -\sum_{v=1}^{V} \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}
$$

IV(a) 称为属性a的固有值

增益率则对可取数目较少的属性有所偏好，因此CP4.5算法不是直接选择增益率最大的侯选属性划分，而是先从候选划分属性中找出信息增益高于平均水平的属性，再从中选择增益率高的。

4.2.3基尼系数（Gini index）

Gini(D)反映了从数据集中随机抽取两个样本，其类别标记不一致的概率。因此Gini(D)越小，则数据集D的纯度越高。

$$
\begin{aligned}
\mathrm{Gini}(D) &= \sum_{k=1}^{|\mathcal{Y}|} \sum_{k' \neq k} p_k p_{k'} \\
&= 1 - \sum_{k=1}^{|\mathcal{Y}|} p_k^2 \ .
\end{aligned}
$$

因此，在侯选属性中，选择基尼指数最小属性的划分